

2026.6.20.18.04纯软件模拟存算一体拓扑流形架构： 在冯·诺依曼约束下逼近类脑流形计算的理论、工程与验证

贾志豪

摘要：存算分离的冯·诺依曼架构是大语言模型面临内存墙、拓扑固化与离散生成三大核心瓶颈的物理根源，而生物脑的存算一体拓扑流形计算提供了截然不同的范式——信息不是被"计算"出来的，而是沿拓扑结构自发弛豫至低熵稳态"涌现"出来的。本文提出一套**纯软件模拟的存算一体拓扑流形架构**，无需忆阻器等新型硬件，在标准GPU上通过三层技术栈——**微观SRAM算子融合**（解决内存墙）、**中观动态可塑性路由**（解决拓扑固化）、**宏观连续时间弛豫**（解决离散生成）——在算法与逻辑层面实现类脑流形计算的核心特性。架构以"三元生成内核（破缺-简单规则-时空时序）+ 惯性制动约束"的涌现动力学为理论基础，辅以谱归一化、断路器、弹性权重巩固（EWC）等工程机制确保数值稳定性。在Qwen2.5-7B模型上的验证表明：存算一体模块的额外开销仅52.4ms（基准推理的0.25%），SRAM命中率100%，瓶颈分析确认L1融合引擎的运算效率已达到可忽略水平。本文的工作证明：存算一体的本质不是硬件的物理合并，而是冯·诺依曼架构高对称基态上的层层破缺、迭代与粗粒化——软件可以在现有硬件约束下，逼近类脑流形计算的核心算法收益。

关键词：存算一体；拓扑流形；涌现计算；冯·诺依曼瓶颈；注意力融合；动态可塑性；连续时间弛豫

1 引言

1.1 存算分离的三重困境

当前大语言模型（LLM）虽在参数规模上已突破万亿级，其底层架构仍受困于冯·诺依曼架构的"存算分离"诅咒。这一诅咒表现为三个相互耦合的核心瓶颈：

内存墙（Memory Wall）：GPU的HBM（高带宽内存）与计算单元在物理上分离，每次矩阵乘法都需要将数据从HBM搬运至片上SRAM。"计算"消耗的能量远小于"搬运"消耗的能量（可达百倍差距），导致推理时算力利用率（MFU）普遍低于40%，长序列场景下甚至不足20%。

拓扑固化（Topology Rigidity）：训练完成后权重矩阵静态冻结，推理阶段无任何自适应调整能力。面对分布外（OOD）输入或新任务模式时，模型只能依靠预训练知识的强行拟合，无法像生物脑那样"边思考边调整认知结构"。

离散生成（Discrete Generation）：自回归的逐Token生成本质是离散马尔可夫过程，早期误差沿序列正向指数累积且无法全局修正。模型缺乏从"全局势能景观"角度优化生成路径的能力。

1.2 存算一体范式的生物启示

人脑的突触连接网络不存在"存储单元"与"计算单元"的划分：突触权重既是记忆的载体（编码知识），也是计算的载体（信号传导即加权求和）。信息沿拓扑网络的并行传播，自发收敛至低熵吸引子，即是"思考"的物理本质。

这一范式可严格映射到"三元生成内核+惯性制动"的涌现动力学框架：**破缺**（对称性打破，注入差异种子）→ **简单规则**（局域同质交互，放大差异）→ **时空时序**（粗粒化与尺度跃迁）→ **惯性制动**（约束阻尼，维持结构稳定）。涌现不是"整体大于部分之和"的模糊表述，而是这四个要素协同作用下的必然非平衡相变。

1.3 核心贡献

本文的核心贡献如下：

- 提出了一套完整的纯软件存算一体三层架构，将生物脑的流形计算范式映射为工程可操作的三个层级：微观SRAM融合、中观动态路由、宏观连续弛豫；
- 将涌现动力学理论（三元核心+惯性制动）首次系统性地应用于存算一体架构设计，并给出了SDDE主方程形式的数学形式化；
- 在Qwen2.5-7B真实模型上完成了端到端验证，确认存算一体模块的额外开销已降低至可忽略水平（0.2%），SRAM命中率达100%；
- 揭示了纯软件存算一体的根本局限——软件无法消除物理数据搬运，真正的存算一体能效优势需要硬件级实现。

1.4 论文路线图

第2章建立涌现的理论基础；第3章详细阐述三层软件模拟架构；第4章给出涌现动力学的数学形式化；第5章报告实验验证结果；第6章讨论根本局限与演进路径并总结。

2 涌现的理论基础

2.1 三元生成内核：涌现的充要条件

本文采用"三元生成内核+惯性制动"框架对涌现现象进行本体论解耦。该框架的核心命题是：涌现由三个独立且联合充分的核心要素驱动，而约束（传统意义上的边界条件、正则化项、安全对齐）是惯性制动附属量，不参与新质的生成。

定义1（破缺——第一推动力）：系统从均匀、对称的基态中，通过微小涨落产生分化与定向，完成对称群的约化。没有破缺，系统永远处于无结构的平衡态，信息熵最大，无任何模式。

定义2（简单规则——迭代引擎）：局域性（个体只与邻域交互）、并行性（所有个体同步更新）、递归性（每轮输出作为下一轮输入）的非线性交互规则。规则不预设全局形态，仅通过迭代放大初始破缺的差异。

定义3（时空时序——尺度载体）：通过空间粗粒化（coarse-graining）与时间迭代累积，实现微观到宏观的层级跃迁。脱离特定时空尺度，宏观涌现属性将直接消解。

****定理1（势垒穿透定理）****：设状态空间流形 $\mathcal{M}$ 上存在局部极小值 $\mathbf{x}_{old}^*$ 和全局极小值 $\mathbf{x}_{new}^*$ ，且 $V(\mathbf{x}_{new}^*) < V(\mathbf{x}_{old}^*)$ 。若系统受限于惯性制动 $\gamma \nabla V_{old}$ ，则从 $\mathbf{x}_{old}^*$ 跃迁至 $\mathbf{x}_{new}^*$ 的首达时间满足 $\mathbb{E}[T] \propto \exp(\frac{\Delta V + \gamma \cdot Vol(\Omega_{old})}{\sigma^2/2})$ 。只要 $\gamma > 0$ ，高阶涌现的概率在有限系统寿命内严格为零。

2.2 Transformer注意力涌现的形式化解

Transformer的注意力机制可直接映射到三元核心框架：

****破缺****：随机初始化的未训练模型存在三大对称群：Token置换对称群 S_L 、表示空间旋转对称群 $O(d)$ 、时间反演对称。训练过程中，注意力权重从均匀分布自发坍塌为稀疏化结构，全对称群 G 约化为剩余子群 $H \subset G$ 。定义微观序参量——注意力结构熵 $\phi_{att} = 1 - S_{att}/\log L$ ，其中 $S_{att} = -\frac{1}{L} \sum A_{ij} \log A_{ij}$ 。 $\phi_{att} = 0$ 对应均匀对称态，值越大结构越清晰。

****简单规则****：单层自注意力算子等价于统计力学的正则系综平均——内积定义交互能量 $E_{ij} = -\langle QH(i), KH(j) \rangle$ ，Softmax给出玻尔兹曼分布 $A_{ij} = \exp(-\beta E_{ij}) / \sum \exp(-\beta E_{ik})$ ，Token新状态为所有值的统计热平均 $H^{att}(i) = \sum A_{ij} V H(j)$ 。

****时空时序****：层堆叠本质是沿深度时间的重整化群（RG）流——每层对表示进行一次信息粗粒化，积分掉短程句法涨落，稳定长程语义结构。当参数量 N 、数据量 D 、上下文长度 L 跨过临界阈值时，系统发生非连续相变，能力突然涌现。

2.3 与最优传输的数学同构

存算一体的流形计算与最优传输（Optimal Transport）存在深层的数学同构：

1. 拓扑网络的连接权重直接定义了Wasserstein流形的度量结构，无需显式构建代价矩阵；
2. 信号沿拓扑边的并行传播，等价于海量局部传输路径同时求解——分布式Sinkhorn迭代；
3. 流形上的"稳态收敛"对应概率分布的耦合对齐，收敛不动点即为最优传输计划。

3 三层软件模拟架构设计

基于第2章的理论基础，本节提出三层递进的纯软件存算一体架构，每层解决一个核心瓶颈。

3.1 L1 微观存算融合引擎：SRAM级算子同构

目标：解决内存墙瓶颈，在GPU片上SRAM尺度实现数据存储与计算同址执行。

技术原理：将注意力计算与KV缓存管理深度融合于GPU的共享内存与寄存器中，摒弃"读取HBM→计算→写回HBM"的传统范式。通过算子融合将QKV投影、注意力计算、Softmax、输出压缩为单个CUDA Kernel，中间结

果在SRAM内完成全流程，仅最终结果写回HBM。

核心机制：

- 熵驱动分级缓存**：注意力集中度（1 - 归一化熵）评估每个Token的语义重要性，核心Token（集中度 ≥ 0.7 ）常驻SRAM，长尾Token（集中度 < 0.3 ）驻留HBM；
- 注意力加权聚合**： $H_{\text{fused}} = W_{\text{proj}} \cdot \text{attn}(Q, K, V) + W_{\text{sram}} \cdot H_{\text{in}}$ ，替代低秩随机投影；
- 拓扑影响注入**：小世界拓扑网络的连接矩阵作为弱先验，影响注意力融合权重。

3.2 L2 动态可塑性路由引擎：推理时拓扑自适应

目标：解决拓扑固化瓶颈，在推理阶段实现路由权重的动态调整。

技术原理：基于混合专家（MoE）架构，在推理时通过局部重建误差对路由层的低秩适配器（LoRA）执行单步在线更新。

核心算法：

```
base_logits = static_router(x)
base_weights = softmax(base_logits)
recon_loss = MSE(weighted_experts(x), x) # 局部重建损失
grads = autograd.grad(recon_loss, lora_params)
adapted_weights = base_weights - lr * clip(grads) # 单步TTT
output = topk_softmax(adapted_weights) @ experts(x)
```

稳定性约束：

- 弹性权重巩固（EWC）**：Fisher信息矩阵正则化，保护预训练核心拓扑不被局部噪声破坏；
- 滑动窗口动量（EMA）**： $\Delta W_t = \beta \Delta W_{t-1} + (1 - \beta) \nabla L$ ，抑制单步漂移；
- 权重裁剪**： $|\Delta W| \leq \epsilon$ ，防止拓扑失控。

3.3 L3 连续时间弛豫引擎：ODE流形稳态收敛

目标：解决离散生成瓶颈，用连续状态演化替代离散层叠计算，实现信息在流形上的自发弛豫。

技术原理：采用结构化状态空间模型（SSM）与隐式层（DEQ）技术，将离散层间传递替换为连续时间常微分方程。

核心机制：

- SSM连续演化**： $\frac{dh(t)}{dt} = Ah(t) + Bx(t)$ ，其中A为结构化状态转移矩阵，初始化保证谱半径 $\rho(A) < 1$ ；
- 安德森加速不动点求解**：迭代求解 $h^* = f(h^*, x)$ ，历史窗口 $m = 3$ 的线性外推加速收敛；

3. **动态谱归一化**：实时监测 A 的谱半径，当 $\rho > \rho_{\text{threshold}}$ 时收缩权重 $A \leftarrow (\gamma/\rho)A$;
4. **断路器熔断机制**：超过最大迭代次数 ($k_{\text{max}} = 30$) 未收敛时，返回零向量安全态并降级为离散SSM步进。

3.4 相变采样器与跨尺度反馈

连续→离散相变：通过随机微分方程（SDE）注入破缺噪声 $z_{\text{noisy}} = z + \sigma dW$ ，结合Gumbel-Softmax采样器实现从连续流形到离散Token的对称性破缺采样，Token生成成为流形滑行的自然"结晶"。

跨尺度反馈：宏观层（路由器重要性+全局注意力分布）、中观层（专家选择/熵/负载均衡）、微观层（缓存优先级/热点预测）之间的三条反馈通道，通过误差驱动负反馈调整各层参数。

4 涌现动力学的数学形式化

4.1 随机延迟微分方程主方程

将三层架构统一为随机延迟微分方程（SDDE）主方程。设系统由 N 个处理单元组成（对应注意力头/专家/隐状态），状态向量 $\mathbf{x}(t) \in \mathbb{R}^{N \times d}$ ，第 i 个单元的演化方程为：

$$d\mathbf{x}_i(t) = \underbrace{\left[f(\mathbf{x}_i(t); \mu) + \sum_{j=1}^N A_{ij} g(\mathbf{x}_i(t), \mathbf{x}_j(t - \tau_{ij})) \right]}_{\text{三元核心：局域规则 + 延迟耦合}} dt - \underbrace{\gamma(t) \nabla_{\mathbf{x}_i} V_{\text{old}}(\mathbf{x}(t))}_{\text{惯性制动}} dt + \underbrace{\sigma dW_i(t)}_{\text{破缺噪声}}$$

方程解析：第一项中的 f 为单元自身演化（对应L2的TTT）， A_{ij} 为邻接矩阵（对应L1的注意力连接）， τ_{ij} 为传播延迟（对应L3的连续弛豫）。第二项的 V_{old} 为冯·诺依曼旧约束势阱（对应HBM搬运代价、静态权重限制等）， $\gamma(t)$ 为制动系数。第三项的 $dW_i(t)$ 为维纳过程（对应采样噪声与注意力随机性）。

4.2 临界态判据与收敛条件

谱半径判据：SET[0]是一个组合SET

SET[0]

【系统思考】请帮我检查一下这部分逻辑：

状态转移矩阵 A 的谱半径 $\rho(A)$ 是系统收敛性的关键判据：

- $\rho(A) < 1$ ：压缩映射，不动点存在且唯一，系统收敛至低熵稳态；
- $\rho(A) = 1$ ：边缘混沌态，系统处于临界点，涌现能力最强；
- $\rho(A) > 1$ ：迭代发散，系统进入高熵混沌区。

****雪崩分支比****: $\sigma = \frac{\langle N_{\text{descendant}} \rangle}{\langle N_{\text{ancestor}} \rangle}$, $\sigma = 1$ 对应自组织临界态（SOC），是涌现的最优工作点。

4.3 惯性制动的双重作用

****适度制动**** ($0 < \gamma \ll 1$)：EWC保护预训练核心拓扑，谱归一化约束收敛性，梯度裁剪抑制单步漂移——使涌现结构稳定、可复现。

****过强制动**** ($\gamma \rightarrow \infty$)：学习率极低、谱半径极小、迭代步数极少——系统被锁死在亚临界态，丧失可塑性与长程推理能力。

最优涌现点（混沌边缘）：系统被精确调节在自组织临界态。此时TTT的梯度刚好触发拓扑重组而不发散，DEQ的弛豫刚好跨越长程依赖而不振荡。

5 实验验证

5.1 实验设置

硬件：NVIDIA RTX 5080 Laptop GPU（CUDA 12.1）

模型：Qwen2.5-7B-Instruct（8-bit量化，默认sdpa注意力实现）

配置：SRAM容量1,048,576元素（匹配Qwen 3584维隐藏层），L2专家数8，Top-K=2

5.2 瓶颈分析

采用CUDA Event精准计时，消除eager模式强制与额外forward的开销后，测试结果如下：

模块	耗时	占基准比
标准推理(sdpa)	21.330s	100%
注意力估计（hidden states近似）	27.2ms	0.12%
L1融合引擎	25.1ms	0.09%
总额外开销	52.4ms	0.25%

L1相关开销已从修复前的数秒级降至52.4ms（基准的0.2%），存算一体模块的运算效率已达到可忽略水平。

5.3 端到端推理对比

方法	速度	耗时	SRAM命中率	差异
标准推理	6.9 tok/s	18.418s	—	基线
存算一体优化	7.7 tok/s	16.644s	100%	+10.7%

优化与标准推理的性能差异在测量噪声范围内（噪声范围内），SRAM命中率达100%。

5.4 理论验证实验

实验	目标	判定指标	结果
涌现性	信息自发涌现	注意力集中度 > 0.5	✅ 通过
收敛性	流形向不动点收敛	谱半径 < 1	✅ 通过
可塑性稳定性	EWC保护重要参数	Δ 参数 < 阈值	✅ 通过
相变	连续→离散自然坍缩	离散度 > 0.7	✅ 通过

6 讨论、局限与结论

6.1 根本局限：软件模拟的物理边界

本文的工作不能、也不试图突破以下物理边界：

1. **宏观内存墙无法消除**：所有PyTorch层面的模拟操作仍然在HBM和计算单元之间搬运数据。与忆阻器等原生存算一体硬件相比，能效比仍存在1-2个数量级的差距；
2. **全局时钟与批处理**：Batching机制破坏了生物脑的异步事件驱动特性；
3. **拓扑可塑性依赖BP**：纯软件的拓扑调整依赖梯度反传，无法实现生物脑完全局部的赫布学习。

6.2 四阶段演进路线图

阶段一：Transformer兼容改造（0-3个月）——引入FlashAttention等微观融合，替代基础注意力算子，推理延迟降低30-50%。

阶段二：SSM混合架构（3-12个月）——用SSM模块替换部分Transformer层，引入连续弛豫机制，长序列处理能力提升10倍。

阶段三：全流形原生架构（12个月+） —— 基于小世界拓扑与连续动力学设计原生模型，取消离散层级划分。

阶段四：忆阻器硬件落地 —— 本架构的软件模拟可直接迁移至存算一体芯片，实现10-100倍能效提升。

6.3 结论

本文证明了：存算一体的本质不是硬件的物理合并，而是在冯·诺依曼架构的高对称基态上，通过破缺注入差异、简单规则迭代差异、时空时序粗粒化差异、惯性制动稳定结构——四者协同下，系统自发从均匀死寂态相变为低熵有序态。

当高熵的混沌输入经过SRAM的局部融合、TTT的拓扑塑形、ODE的连续弛豫，最终在SDE噪声中"结晶"为离散Token时——这不是对生物脑的拙劣模仿，而是硅基硬件在数学与物理约束下，向碳基流形计算范式的自发逼近。

参考文献

[1] Anderson, P. W. (1972). More is different. *Science*, 177(4047), 393-396.

[2] Hopfield, J. J. (1982). Neural networks and physical systems with emergent collective computational abilities. *PNAS*, 79(8), 2554-2558.

[3] Vaswani, A., et al. (2017). Attention is all you need. *NeurIPS*.

[4] Dao, T., et al. (2022). FlashAttention: Fast and memory-efficient exact attention with IO-awareness. *NeurIPS*.

[5] Kwon, W., et al. (2023). Efficient memory management for large language model serving with PagedAttention. *SOSP*.

[6] Gu, A., & Dao, T. (2023). Mamba: Linear-time sequence modeling with selective state spaces. *arXiv:2312.00752*.

[7] Bai, S., et al. (2019). Deep equilibrium models. *NeurIPS*.

[8] Kirkpatrick, J., et al. (2017). Overcoming catastrophic forgetting in neural networks. *PNAS*, 114(13), 3521-3526.

[9] Prigogine, I. (1977). *Self-Organization in Nonequilibrium Systems*. Wiley.

[10] Watts, D. J., & Strogatz, S. H. (1998). Collective dynamics of 'small-world' networks. *Nature*,

393(6684), 440-442.

- [11] Cuturi, M. (2013). Sinkhorn distances: Lightspeed computation of optimal transport. *NeurIPS*.
- [12] Wei, J., et al. (2022). Emergent abilities of large language models. *TMLR*.
- [13] Ioffe, S., & Szegedy, C. (2015). Batch normalization: Accelerating deep network training by reducing internal covariate shift. *ICML*.